


GUIDE D'IMPLEMENTATION

Impala via Apache Knox vers PostgreSQL, puis Power BI

Deux méthodes de foreign tables à travers Knox : ODBC FDW et JDBC FDW

Décision recommandée

Pour un pilote, commencer par ODBC FDW 0.6.1 à travers Knox (transport HTTP, compte LDAP validé par Knox), avec des vues Impala dédiées et Power BI en mode Import. Tester JDBC FDW 0.5.0 à travers Knox uniquement si une contrainte impose JDBC ou si son pushdown apporte un gain mesuré. Knox supprime Kerberos et les routes vers les coordinateurs côté PostgreSQL, mais ajoute un saut HTTPS, des délais et une limite de connexions à aligner avant tout test de charge. Les deux extensions sont communautaires ; `odbc_fdw` est archivé et `jdbc_fdw` n'annonce pas de certification Impala.



Public : administrateurs PostgreSQL, Impala et Knox, équipes BI, sécurité et exploitation

Version du document : 1.0 - Situation vérifiée au 1 septembre 2026

Tous les noms d'hôtes, comptes et mots de passe sont des exemples. Remplacez-les dans un coffre de secrets ou dans votre processus de déploiement, jamais dans un dépôt Git.

Sommaire

Sommaire	2
Hypothèses à adapter	3
Variables utilisées dans les exemples	3
1. Aide au choix	4
1.1 Ce que Knox change par rapport à un accès direct	4
1.2 Critères de passage en production	5
2. Architecture et prérequis communs	6
2.1 Flux réseau	6
2.2 Matrice de versions de référence	6
2.3 Comptes et droits	6
3. Préparation commune côté Impala et Knox	7
3.1 Vue d'exposition	7
3.2 Correspondance des types	7
3.3 Prérequis Impala pour un accès via Knox	7
3.4 Prérequis Knox	8
3.5 Tests directs avant PostgreSQL	8
4. Méthode A - <code>odbc_fdw</code> via Knox	10
4.1 Installer unixODBC, le pilote et les en-têtes	10
4.2 Installer la chaîne CA de Knox au format PEM	10
4.3 Déclarer le pilote et le DSN Knox	10
4.4 Tester comme l'utilisateur système postgres	11
4.5 Compiler et installer <code>odbc_fdw</code> 0.6.1	11
4.6 Créer le serveur, le mapping et la foreign table	11
4.7 Valider le chemin ODBC via Knox	12
5. Méthode B - <code>jdbc_fdw</code> via Knox	13
5.1 Installer le JDK et les dépendances de build	13
5.2 Installer le pilote Cloudera JDBC	13
5.3 Créer le truststore JKS contenant la CA de Knox	13
5.4 Compiler <code>jdbc_fdw</code> v0.5.0	13
5.5 Rendre libjvm disponible au runtime	14
5.6 URL JDBC via Knox	14
5.7 Tester le JAR indépendamment du FDW, sous l'identité postgres	14
5.8 Créer le serveur JDBC	15
5.9 Créer les foreign tables manuellement	15
5.10 Durcir <code>jdbc_fdw</code> et valider	16
5.11 Pushdown et limites à connaître	16
5.12 Particularités Knox côté JDBC	16
6. Couche PostgreSQL commune et sécurisée	17
6.1 Exposer une vue de reporting	17
6.2 Protéger PostgreSQL	17
6.3 Secrets	17
6.4 Paramètres de délai cohérents	18
7. Connexion Power BI à PostgreSQL	19
7.1 Power BI Desktop	19
7.2 Gateway Power BI Service	19
7.3 Import ou DirectQuery	19
8. Plan de tests et critères d'acceptation	20
8.1 Exactitude fonctionnelle	20
8.2 Performance	20
8.3 Résilience	20
8.4 Tests spécifiques Knox	21
8.5 Comparaison A/B	21
9. Exploitation et diagnostic	22

9.1 Supervision minimale	22
9.2 Symptômes fréquents	22
9.3 Requêtes de diagnostic PostgreSQL	23
10. Retour arrière et recommandation finale	24
10.1 Basculer de JDBC vers ODBC, ou inversement	24
10.2 Retirer une méthode	24
10.3 Recommandation	24
11. Références et checklist de mise en service	25
11.1 Références primaires	25
11.2 Checklist go/no-go	25

Périmètre

Flux en lecture seule : Impala -> Knox -> PostgreSQL -> Power BI. Knox est l'unique point d'entrée vers Impala depuis PostgreSQL ; le port binaire 21050 n'est pas exposé. La procédure ne traite pas de réplication transactionnelle ni d'écriture dans Impala via PostgreSQL.

Hypothèses à adapter

- PostgreSQL 17 sous Linux, car jdbc_fdw v0.5.0 annonce le support jusqu'à PostgreSQL 17. PostgreSQL 18 n'est pas retenu pour le chemin JDBC.
- Apache Knox est déployé avec le cluster (CDP ou équivalent) : une topologie API expose le service IMPALA (en général cdp-proxy-api), Knox écoute en HTTPS 8443 (443 en CDP Public Cloud) et authentifie les comptes par LDAP (ShiroProvider).
- Impala expose HiveServer2 en HTTP (hs2_http_port, 28000 par défaut) sur les coordinateurs référencés dans la topologie, et reconnaît Knox comme proxy de confiance. Port, topologie et mode de confiance doivent être confirmés avec l'équipe plateforme.
- Un compte LDAP technique svc_powerbi_impala est autorisé sur la topologie Knox et dispose uniquement de SELECT sur des vues Impala dédiées.
- Power BI Service accède à PostgreSQL privé via une passerelle locale standard ; Desktop peut accéder directement au réseau interne.
- Les requêtes sont optimisées dans Impala avant exposition. Les types complexes sont aplatis.

Variables utilisées dans les exemples

Variable	Exemple	À confirmer
Hôte Knox (VIP / LB)	knox-lb.example.local	DNS, SAN du certificat, cluster Knox
Port Knox	8443 (443 en CDP Public Cloud)	Filtrage réseau PostgreSQL -> Knox
Chemin HTTP (HttpPath)	gateway/cdp-proxy-api/impala	Chemin gateway + topologie + service
CA Knox (PEM)	/etc/knox/ca-chain.pem	Chaîne complète, lisible par postgres
Truststore JDBC	/etc/knox/knox-truststore.jks	CA Knox importée(s)
Base Impala	analytics	Base contenant la vue BI
Vue Impala	v_ventes_powerbi	Colonnes et volumétrie
Compte technique	svc_powerbi_impala	LDAP interrogé par Knox ; politique de verrouillage
Hôte PostgreSQL	pg-bi.example.local:5432	TLS et filtrage réseau
Base PostgreSQL	bi_gateway	Sauvegarde et supervision
Rôle Power BI	pbi_reader	SCRAM, rotation, Gateway

1. Aide au choix

Aucune des deux méthodes ne transforme PostgreSQL en moteur de cache. Chaque requête sur une foreign table peut atteindre Impala, à travers Knox. Power BI en DirectQuery ajoute donc trois couches réseau (Gateway, PostgreSQL, Knox) et deux planificateurs. La sélection doit être fondée sur un PoC mesuré, pas seulement sur la possibilité de se connecter.

Critère	ODBC FDW 0.6.1	JDBC FDW 0.5.0	Lecture
État amont	Dépôt archivé ; 0.6.1 corrige des sujets de sécurité	Projet communautaire ; dernière release v0.5.0	Risque de maintenance dans les deux cas
Version PostgreSQL	Fork annoncé pour versions récentes ; valider le binaire	PG 13 à 17 ; pas PG 18 annoncé	Base commune conseillée : PG 17
Runtime	unixODBC + pilote Cloudera ODBC	JVM/JNI + JAR Cloudera JDBC	JDBC est plus complexe à exploiter
Transport via Knox	HTTP : TransportMode=http + HttpPath	HTTP : TransportMode=http + httpPath	Identique ; chaque appel Thrift devient une requête HTTPS
Sticky session Knox	À valider ; des retours d'expérience montrent des échecs ODBC sur topologie sticky	Cookie géré par le client HTTP du pilote ; à valider	Tester avec au moins deux coordinateurs
Pushdown annoncé	Très limité ; vérifier la requête distante	Filtres, colonnes, agrégats simples	Réduire le volume transféré à travers Knox compte davantage
Schémas	Création manuelle ou import à tester	Création manuelle ; import Impala non pris en charge	Préférer DDL versionné
Écriture	Lecture seule	FDW génériquement inscriptible, mais à désactiver	Imposer updatable=false et droits Impala SELECT
DirectQuery	Possible, mais sensible aux aller-retours (+ Knox)	Possible, mêmes réserves + coût JVM	Import par défaut
Choix	Premier PoC recommandé	PoC alternatif si JDBC est requis	ETL local ou connecteur Impala direct pour la production critique

1.1 Ce que Knox change par rapport à un accès direct

Élément	Accès direct à Impala	Accès via Knox
Cible réseau depuis PostgreSQL	impala-lb:21050 (binaire) ou :28000 (HTTP)	knox-lb:8443 (HTTPS) uniquement
Transport Thrift	Binaire par défaut	HTTP obligatoire : TransportMode=http + HttpPath
Certificat vérifié par le pilote	Celui d'Impala / du LB Impala	Celui de Knox (CA interne, souvent Auto-TLS)
Authentification du pilote	LDAP ou Kerberos directement sur Impala	AuthMech=3 (Basic) validé par Knox ; Knox se présente ensuite à Impala et impersonne l'utilisateur
Kerberos côté serveur PostgreSQL	Possible (keytab, KDC)	Non nécessaire
Répartition / HA	Load balancer Impala	HaProvider Knox (sticky session par cookie) ou LB devant Knox
Délais supplémentaires	-	gateway.httpClient.socketTimeout et connectionTimeout, 20 s par défaut
Concurrence	Admission control Impala	+ gateway.httpClient.maxConnections, 32 par hôte:port par défaut
Audit	Impala / Ranger	+ gateway-audit.log Knox (utilisateur, chemin, code HTTP)
Coût	-	Latence HTTP + saut Knox ; à mesurer en A/B si un accès direct existe

Décision d'architecture


Si PostgreSQL n'apporte ni gouvernance, ni sécurité, ni vues métier, ni mutualisation, le connecteur Impala natif de Power BI est plus simple, sous réserve de sa compatibilité avec votre mode d'accès (Knox / HTTP). Si les données doivent être rapides et stables à grande échelle, matérialiser les jeux BI dans PostgreSQL par ETL/ELT reste généralement plus robuste qu'un double relais DirectQuery à travers Knox.

1.2 Critères de passage en production

- **Exactitude** : mêmes comptes, sommes et décimales entre Impala, PostgreSQL et Power BI.
- **Performance** : temps P95 conforme à votre SLO, avec la concurrence Power BI réelle, mesuré à travers Knox.
- **Filtrage** : preuve par EXPLAIN VERBOSE et profil Impala que les prédicats sélectifs sont exécutés côté Impala.
- **Sécurité** : TLS des trois segments, compte Impala en SELECT, secrets rotatifs, droits FDW minimaux, aucun mode trust-all.
- **Résilience** : reprise après indisponibilité d'Impala ou de Knox, annulation, délais (dont ceux de Knox) et saturation de connexions testés.
- **Exploitabilité** : versions épinglées, procédure de reconstruction, supervision (dont l'audit Knox) et retour arrière documentés.

2. Architecture et prérequis communs

2.1 Flux réseau



Flux à autoriser : Power BI Gateway -> PostgreSQL 5432/TLS ; PostgreSQL -> Knox 8443/HTTPS ; Knox -> coordinateurs Impala 28000 (géré par l'équipe plateforme). Aucun flux PostgreSQL -> 21050/28000 ni PostgreSQL -> KDC n'est requis : le serveur PostgreSQL n'a pas besoin de résoudre les noms des impalad ni de joindre Kerberos.

Source	Destination	Port	Contrôle
Gateway Power BI	PostgreSQL	5432/TCP	TLS, CA validée, liste d'IP, SCRAM
Serveur PostgreSQL	Knox (VIP / LB)	8443/TCP	TLS, CA Knox validée, Basic auth LDAP
Knox	Coordinateurs Impala HS2 HTTP	28000/TCP	TLS, Kerberos/SPNEGO ou domaine de confiance (plateforme)
Knox	LDAP / AD	389 ou 636/TCP	Authentification du compte technique
Serveur PostgreSQL	DNS	53	Résolution de la VIP Knox uniquement

2.2 Matrice de versions de référence

Composant	Version de référence	Règle
PostgreSQL	17.x	Épingler la mineure et appliquer les correctifs
odbc_fdw	Tag 0.6.1	Source archivée ; conserver SHA et paquet interne
unixODBC	Version OS supportée	Même version en build et runtime
Cloudera ODBC	2.9.0 ou version certifiée cluster	Transport HTTP requis ; suivre le guide du ZIP exact
jdbc_fdw	Tag v0.5.0	PG 13 à 17 ; ne pas utiliser main en production
JDK	17 dans cet exemple	Valider le couple JDK/jdbc_fdw/pilote ; Java 8 est la référence historique du README
Cloudera JDBC	2.6.39 ou version certifiée cluster	Vérifier le manifeste du JAR et le guide livré
Apache Knox	Version livrée avec le cluster	Relever version, topologie, paramètres HaProvider et httpclient dans le dossier de livraison
Impala	Version du cluster	HS2 HTTP activé ; confiance envers Knox configurée
Power BI	Version d'entreprise	Desktop, Service et Gateway alignés

Point de contrôle

La page Cloudera peut afficher une version différente de celle inscrite dans le PDF ou le JAR téléchargé. Enregistrez le SHA-256, le manifeste du JAR, le ZIP, le guide et la date de téléchargement dans votre dossier de livraison. Ajoutez-y la version de Knox, le nom de la topologie et l'export des paramètres HaProvider et httpclient : ils conditionnent le comportement du montage autant que les pilotes.

2.3 Comptes et droits

Identité	Usage	Droits
svc_powerbi_impala	PostgreSQL -> Knox -> Impala	Compte LDAP ; autorisé sur la topologie Knox ; SELECT uniquement sur vues BI (Ranger)
Identité Knox (principal knox)	Knox -> Impala	Proxy de confiance : impersonne svc_powerbi_impala ; aucun droit propre sur les données
fdw_owner	Propriétaire FDW	CREATE SERVER, mappings ; pas de connexion Power BI
pbi_reader	Gateway / Power BI	CONNECT + USAGE reporting + SELECT vues
postgres système	Processus OS	Lecture pilotes, JAR, CA Knox ; réseau vers Knox uniquement

3. Préparation commune côté Impala et Knox

La meilleure optimisation se fait avant le FDW. Créez une vue Impala stable, étroite et orientée BI, puis faites valider par l'équipe plateforme son exposition à travers Knox. La vue doit masquer les tables brutes, aplatir les types complexes et appliquer les conversions explicitement.

3.1 Vue d'exposition

Impala SQL - exemple à adapter

```
CREATE DATABASE IF NOT EXISTS analytics;

CREATE VIEW analytics.v_ventes_powerbi AS
SELECT
  CAST(v.vente_id      AS BIGINT)      AS vente_id,
  CAST(v.client_id    AS BIGINT)      AS client_id,
  CAST(v.date_vente    AS TIMESTAMP)   AS date_vente,
  CAST(v.montant       AS DECIMAL(18,2)) AS montant,
  CAST(v.pays         AS STRING)       AS pays,
  CAST(v.date_partition AS DATE)       AS date_partition
FROM raw.ventes v
WHERE v.statut = 'VALIDE';

GRANT SELECT ON TABLE analytics.v_ventes_powerbi
TO USER svc_powerbi_impala;
```

Selon Ranger, Sentry ou votre mécanisme d'autorisation, le GRANT peut être administré ailleurs. Le résultat attendu reste un compte technique limité à la vue. À travers Knox, l'utilisateur effectif dans Impala est l'utilisateur impersonné : la politique doit viser svc_powerbi_impala, pas l'identité Knox.

3.2 Correspondance des types

Impala	PostgreSQL	Contrôle
BOOLEAN	boolean	NULL et true/false
TINYINT / SMALLINT	smallint	Bornes
INT	integer	Bornes
BIGINT	bigint	Pas de conversion en double
FLOAT	real	Comparaison avec tolérance
DOUBLE	double precision	Précision attendue
DECIMAL(p,s)	numeric(p,s)	Échelle, arrondi, valeurs négatives
STRING / CHAR / VARCHAR	text	UTF-8, accents, longueurs
DATE	date	Dates limites et NULL
TIMESTAMP	timestamp without time zone	Convention UTC explicite
ARRAY / MAP / STRUCT	Non exposé directement	Aplatir dans une vue Impala

3.3 Prérequis Impala pour un accès via Knox

- HS2 **HTTP** activé sur les coordinateurs : hs2_http_port (28000 par défaut). Knox ne proxye pas le port binaire 21050.
- Impala doit **faire confiance à Knox** pour l'identité transmise. Selon la version et la politique du cluster : soit Knox s'authentifie en Kerberos/SPNEGO auprès d'Impala et impersonne l'utilisateur (doAs), auquel cas le principal Knox figure dans authorized_proxy_user_config ou authorized_proxy_group_config ; soit Impala considère Knox comme source de confiance (trusted_domain, trusted_domain_use_xff_header, trusted_auth_header) et prend l'utilisateur transmis sans ré-authentifier.
- Dans les deux cas, **l'utilisateur effectif côté Impala et Ranger reste svc_powerbi_impala**. Dans le profil Impala d'une requête, contrôler : Connected User = identité Knox, Delegated User = svc_powerbi_impala.
- idle_session_timeout et idle_query_timeout cohérents avec des connexions FDW qui restent ouvertes dans les backends PostgreSQL.

3.4 Prérequis Knox

Sujet	À confirmer	Pourquoi
Topologie API exposant le service IMPALA	cdp-proxy-api en général	La topologie UI (cdp-proxy) n'expose pas l'endpoint Thrift
Chemin gateway	gateway sur CDP Private Cloud Base ; nom du Data Hub sur CDP Public Cloud (port 443)	Il forme le début du HttpPath
HttpPath complet	gateway/cdp-proxy-api/impala	Valeur à copier telle quelle dans le DSN et l'URL JDBC
Authentification	ShiroProvider LDAP (Basic)	Détermine AuthMech=3 et l'annuaire où doit exister le compte
Autorisation Knox	ACL de topologie ou politique Ranger « Knox » (topologie + service)	Un refus ici donne un HTTP 403 avant même d'atteindre Impala
HA / répartition	HaProvider avec IMPALA : enableStickySession=true;enableLoadBalancing=true;noFallback=...	Une session Impala est liée à un coordinateur : sans sticky session, erreurs de session ou de handle
Cookie de stickiness	KNOX_BACKEND-IMPALA (défaut KNOX_BACKEND-{service})	Le pilote doit renvoyer ce cookie
Délais	gateway.httpclient.socketTimeout et connectionTimeout (20 s par défaut) ; surcharge par service possible (httpClient.socketTimeout dans la topologie)	À aligner sur statement_timeout et querytimeout (\$6.4)
Connexions	gateway.httpclient.maxConnections (32 par hôte:port par défaut)	Chaque backend PostgreSQL actif consomme des connexions Knox -> Impala
Certificat	Chaîne CA du certificat Knox ; SAN = nom DNS de la VIP utilisée	Obligatoire pour TrustedCerts (ODBC) et SSLTrustStore (JDBC)
Page d'accueil Knox	Les versions récentes affichent une URL JDBC Impala prête à l'emploi	Base fiable pour l'URL de jdbc_fdw

Point de contrôle

La page d'accueil Knox, si elle est activée, donne l'hôte, le port et le HttpPath exacts. Sinon, demandez le fichier de topologie (cdp-proxy-api.xml) : il contient les URL du service IMPALA (https://impalad-x:28000/) et les paramètres HaProvider. Relevez aussi la version de Knox et les paramètres httpClient.

3.5 Tests directs avant PostgreSQL

- Exécuter `SHOW TABLES IN analytics` et `DESCRIBE analytics.v_ventes_powerbi` avec le compte technique, à travers Knox (impala-shell en protocole hs2-http avec le chemin Knox, ou tout client ODBC/JDBC indépendant).
- Comparer `COUNT(*)`, `COUNT(DISTINCT vente_id)`, `SUM(montant)`, `MIN/MAX(date_vente)`.
- Tester un filtre très sélectif sur `date_partition` et contrôler le profil Impala (Delegated User, temps, octets lus).
- Valider TLS, authentification et routage Knox avec les deux commandes ci-dessous, sous l'identité système postgres.

Shell - chaîne de certificats et SAN de Knox

```
# Récupérer la chaîne présentée par Knox et vérifier le SAN
openssl s_client -connect knox-lb.example.local:8443 \
  -servername knox-lb.example.local -showcerts </dev/null \
  | openssl x509 -noout -subject -issuer -ext subjectAltName

# Vérifier que la CA locale valide bien le serveur
openssl s_client -connect knox-lb.example.local:8443 \
  -servername knox-lb.example.local -CAfile /etc/knox/ca-chain.pem </dev/null \
  | grep 'Verify return code'
# Attendu : Verify return code: 0 (ok)
```

Shell - authentification et routage Knox (curl demande le mot de passe)

```
curl -sS -o /dev/null -w 'HTTP %{http_code}\n' \  
  --cacert /etc/knox/ca-chain.pem \  
  -u svc_powerbi_impala \  
  https://knox-lb.example.local:8443/gateway/cdp-proxy-api/impala
```

Code HTTP	Lecture
401	Knox refuse l'identifiant : mot de passe, compte verrouillé, mauvais LDAP ou realm
403	Authentifié mais non autorisé : ACL de topologie, politique Ranger Knox, ou Impala refuse l'impersonation
404	HttpPath incorrect : chemin gateway, topologie ou nom de service
502 / 503 / 504	Knox ne joint pas les coordinateurs : 28000 fermé, HS2 HTTP désactivé, TLS Knox -> Impala, délai
Autre (400, 405...)	Knox a authentifié et routé la requête ; l'endpoint Thrift refuse simplement un GET. Ce n'est pas un test fonctionnel : passer à isql ou au client JDBC

Ne continuez pas si un test direct échoue

Une erreur à ce stade relève de Knox, du LDAP, du réseau ou du TLS, pas du pilote ni du FDW PostgreSQL. Demandez à l'équipe plateforme l'entrée correspondante dans gateway-audit.log (utilisateur, chemin, code) avant d'aller plus loin.

4. Méthode A - odbc_fdw via Knox

Positionnement

Méthode la plus directe pour le premier PoC. Le fork 0.6.1 corrige des problèmes de sécurité, mais son dépôt est archivé. À travers Knox, le pilote ODBC Cloudera bascule en transport HTTP : seuls le DSN et la CA changent par rapport à un accès direct. Construire un paquet interne reproductible et ne pas déléguer la création de serveurs FDW à des rôles non fiables.

4.1 Installer unixODBC, le pilote et les en-têtes

Shell - Debian/Ubuntu

```
sudo apt-get update
sudo apt-get install -y build-essential git unixodbc unixodbc-dev \
    postgresql-server-dev-17
# Installer ensuite le paquet Cloudera ODBC validé par votre équipe.
# Exemple de répertoire cible : /opt/cloudera/impalaodbc/
```

Sur RHEL/Rocky, utiliser les équivalents `gcc make git unixODBC unixODBC-devel postgresql17-devel`. Ne mélangez pas des bibliothèques de distributions différentes.

4.2 Installer la chaîne CA de Knox au format PEM

Shell - CA lisible par postgres uniquement

```
sudo install -d -m 0755 /etc/knox
sudo install -o root -g postgres -m 0640 ca-chain.pem /etc/knox/ca-chain.pem
sudo -u postgres test -r /etc/knox/ca-chain.pem && echo "lisible par postgres"
```

Le pilote ODBC Cloudera utilise par défaut le fichier `cacerts.pem` livré avec lui ; une CA interne doit donc être fournie explicitement via `TrustedCerts`. Le PEM peut contenir toute la chaîne (racine et intermédiaires).

4.3 Déclarer le pilote et le DSN Knox

/etc/odbcinst.ini

```
[Cloudera ODBC Driver for Impala 64-bit]
Description=Cloudera ODBC Driver for Impala 64-bit
Driver=/opt/cloudera/impalaodbc/lib/64/libclouderaimpalaodbc64.so
```

/etc/odbc.ini - LDAP via Knox, transport HTTP, sans mot de passe

```
[IMPALA_KNOX]
Driver=Cloudera ODBC Driver for Impala 64-bit
Description=Impala via Knox (topologie cdp-proxy-api)
HOST=knox-lb.example.local
PORT=8443
Database=analytics
TransportMode=http
HttpPath=gateway/cdp-proxy-api/impala
AuthMech=3
SSL=1
TrustedCerts=/etc/knox/ca-chain.pem
AllowSelfSignedServerCert=0
AllowHostNameMismatch=0
```

- Les noms de clés exacts (`TransportMode`, `HttpPath`, `TrustedCerts`...) sont ceux du guide livré avec le ZIP du pilote ; vérifiez-les pour la version 2.9.0 ou celle certifiée pour votre cluster.
- Sur CDP Public Cloud : `PORT=443` et `HttpPath=<nom-du-datahub>/cdp-proxy-api/impala`.
- Le fichier de configuration du pilote (`cloudera.impalaodbc.ini`, à côté de la bibliothèque) doit pointer vers `unixODBC` (`ODBCInstLib`, `DriverManagerEncoding`) ; il porte aussi `LogLevel` et `LogPath`, utiles pendant le PoC pour voir les codes HTTP renvoyés par Knox.
- `RowsFetchedPerBlock` (10000 par défaut) conditionne le nombre d'aller-retours HTTP par requête ; ne le modifiez qu'après mesure.

4.4 Tester comme l'utilisateur système postgres

Shell - session de test uniquement

```
odbcinst -j
odbcinst -q -d
odbcinst -q -s                # IMPALA_KNOX doit apparaître
read -rs -p "Mot de passe LDAP : " IMPALA_PWD; echo
sudo -u postgres isql -v IMPALA_KNOX svc_powerbi_impala "$IMPALA_PWD"
unset IMPALA_PWD
```

isql

```
SQL> SELECT COUNT(*) FROM analytics.v_ventes_powerbi;
```

isql ne demande pas le mot de passe de façon interactive ; le passer en troisième argument l'expose brièvement dans ps. Réservez cette commande à une session de test, ou utilisez un fichier `~postgres/.odbc.ini` temporaire en mode 0600 contenant UID et PWD, supprimé après le test.

Ne continuez pas si isql échoue

Une erreur ODBC à ce stade relève du pilote, du DSN, du réseau, du TLS ou de l'authentification Knox, pas du FDW PostgreSQL. Croisez le message du pilote avec `gateway-audit.log` (§9.2) et corrigez avant de compiler l'extension.

4.5 Compiler et installer odbc_fdw 0.6.1

Shell - build épinglé

```
git clone --branch 0.6.1 --depth 1 https://github.com/devrimgunduz/odbc_fdw.git
cd odbc_fdw
git rev-parse HEAD
make PG_CONFIG=/usr/lib/postgresql/17/bin/pg_config
sudo make install PG_CONFIG=/usr/lib/postgresql/17/bin/pg_config
```

Traçabilité de version

Le tag source peut être 0.6.1 alors que le fichier de contrôle / SQL déclare encore une version d'extension 0.5.2. Conservez le tag, le SHA Git, le hash du paquet et le journal de compilation ; ne vous fiez pas uniquement à `pg_extension.extversion`.

4.6 Créer le serveur, le mapping et la foreign table

PostgreSQL SQL - exécuter comme propriétaire contrôlé

```

CREATE ROLE fdw_owner NOLOGIN;
CREATE ROLE pbi_reader LOGIN PASSWORD '<MOT_DE_PASSE_POSTGRES>';
CREATE EXTENSION odbc_fdw;
CREATE SCHEMA impala_ext AUTHORIZATION fdw_owner;

CREATE SERVER impala_odbc_knox_srv
  FOREIGN DATA WRAPPER odbc_fdw
  OPTIONS (dsn 'IMPALA_KNOX', encoding 'UTF8');

CREATE USER MAPPING FOR pbi_reader
  SERVER impala_odbc_knox_srv
  OPTIONS (
    odbc_UID 'svc_powerbi_impala',
    odbc_PWD '<MOT_DE_PASSE_LDAP_IMPALA>'
  );

CREATE FOREIGN TABLE impala_ext.ventes_odbc_knox (
  vente_id      bigint,
  client_id     bigint,
  date_vente    timestamp without time zone,
  montant       numeric(18,2),
  pays          text,
  date_partition date
)
SERVER impala_odbc_knox_srv
OPTIONS (
  schema 'analytics',
  table  'v_ventes_powerbi'
);

```

- Le mot de passe du mapping est celui que **Knox** valide auprès du LDAP : un mot de passe faux ici, combiné aux tentatives répétées d'un refresh Power BI, peut **verrouiller le compte technique** (§6.3).
- Pour éviter un COUNT(*) distant pendant la planification, mesurez d'abord le comportement sans sql_count. Si nécessaire, fournissez une requête de comptage sûre ou ajustez la stratégie de statistiques après test.
- Les objets sont suffixés _knox pour coexister, si besoin, avec un chemin direct pendant la comparaison ; la bascule se fait par CREATE OR REPLACE VIEW reporting.ventes (§10.1).

4.7 Valider le chemin ODBC via Knox**PostgreSQL SQL - rôle réellement utilisé par Power BI**

```

SET ROLE pbi_reader;
SELECT COUNT(*) FROM impala_ext.ventes_odbc_knox;
SELECT SUM(montant) FROM impala_ext.ventes_odbc_knox
  WHERE date_partition >= DATE '2026-01-01';
EXPLAIN (VERBOSE, COSTS, SETTINGS)
SELECT vente_id, montant
  FROM impala_ext.ventes_odbc_knox
  WHERE date_partition = DATE '2026-08-31';
RESET ROLE;

```

Vérifiez dans gateway-audit.log que chaque exécution apparaît avec svc_powerbi_impala et un code 200, et dans le profil Impala que Delegated User est bien ce compte.

5. Méthode B - jdbc_fdw via Knox

Positionnement

Alternative générique lorsque JDBC est imposé. La release v0.5.0 annonce PostgreSQL 13 à 17 et le pushdown de filtres, colonnes et agrégats simples. Impala n'est pas annoncé comme cible certifiée, et le passage par Knox ajoute le transport HTTP et la gestion des cookies de session : qualifier le JAR, le couple JDK/JNI, la stickiness Knox et la charge concurrente.

5.1 Installer le JDK et les dépendances de build

Shell - identifier le JDK réel

```
sudo apt-get update
sudo apt-get install -y build-essential git libpq-dev postgresql-server-dev-17 \
  openjdk-17-jdk
readlink -f "$(command -v javac)"
find /usr/lib/jvm -name libjvm.so -print
```

Le README jdbc_fdw confirme historiquement OpenJDK 8 ; le guide Cloudera actuel couvre plusieurs JRE, dont 17. JDK 17 est utilisé ici comme exemple moderne, mais le triplet JDK + jdbc_fdw + JAR doit être testé et figé.

5.2 Installer le pilote Cloudera JDBC

- Télécharger le connecteur approuvé depuis Cloudera et vérifier le SHA-256.
- Installer le JAR, par exemple /opt/cloudera/impala-jdbc/ImpalaJDBC42.jar.
- Donner au compte système postgres uniquement le droit de lecture sur le JAR et le truststore.
- Vérifier que le JAR est autonome : jdbc_fdw n'accepte qu'un chemin absolu de JAR ; les distributions multi-JAR nécessitent un test de chargement ou un packaging approuvé.

Shell - permissions du JAR

```
sudo install -o root -g postgres -m 0640 ImpalaJDBC42.jar \
  /opt/cloudera/impala-jdbc/ImpalaJDBC42.jar
sudo -u postgres test -r /opt/cloudera/impala-jdbc/ImpalaJDBC42.jar
```

5.3 Créer le truststore JKS contenant la CA de Knox

Shell - un alias par CA de la chaîne (keytool n'importe que le premier certificat d'un PEM)

```
sudo keytool -importcert -noprompt -alias knox-root-ca \
  -file /etc/knox/root-ca.pem \
  -keystore /etc/knox/knox-truststore.jks -storepass '<MOT_DE_PASSE_TRUSTSTORE>'
# sudo keytool -importcert -noprompt -alias knox-int-ca -file /etc/knox/int-ca.pem ...

sudo chown root:postgres /etc/knox/knox-truststore.jks
sudo chmod 0640 /etc/knox/knox-truststore.jks
sudo -u postgres keytool -list -keystore /etc/knox/knox-truststore.jks \
  -storepass '<MOT_DE_PASSE_TRUSTSTORE>' | grep -i knox
```

Alternative : importer la CA Knox dans le cacerts du JDK figé (\$JAVA_HOME/lib/security/cacerts). L'URL du serveur ne contient alors plus SSLTrustStore ni SSLTrustStorePwd, ce qui évite un mot de passe visible dans pg_foreign_server. À documenter, car une mise à jour du JDK peut écraser le fichier.

5.4 Compiler jdbc_fdw v0.5.0

Shell - adapter LIBDIR au résultat de find

```
git clone --branch v0.5.0 --depth 1 https://github.com/pgspider/jdbc_fdw.git
cd jdbc_fdw
git rev-parse HEAD
make USE_PGXS=1 PG_CONFIG=/usr/lib/postgresql/17/bin/pg_config \
  LIBDIR=/usr/lib/jvm/java-17-openjdk-amd64/lib/server
sudo make install USE_PGXS=1 PG_CONFIG=/usr/lib/postgresql/17/bin/pg_config \
  LIBDIR=/usr/lib/jvm/java-17-openjdk-amd64/lib/server
```

5.5 Rendre libjvm disponible au runtime

Le Makefile lie -ljvm. Le service PostgreSQL doit retrouver exactement la même bibliothèque au démarrage. Préférez une configuration explicite du chargeur dynamique ou du service à un lien symbolique global non documenté.

Shell - diagnostic non destructif

```
# Contrôler les dépendances du module installé.
PG_LIBDIR=$(/usr/lib/postgresql/17/bin/pg_config --pkglibdir)
ldd "$PG_LIBDIR/jdbc_fdw.so"
# Résultat attendu : libjvm.so => chemin absolu du JDK validé.
# Si "not found", configurer ld.so ou l'environnement systemd,
# puis redémarrer PostgreSQL dans une fenêtre de changement.
```

5.6 URL JDBC via Knox

Recopier la syntaxe du guide livré ou l'URL affichée par la page d'accueil Knox. Le pilote envoie un en-tête Basic (AuthMech=3) à chaque requête HTTPS ; Knox le valide auprès du LDAP et transmet l'identité à Impala.

Exemples d'URL - identifiants fournis séparément par le USER MAPPING

```
# CDP Private Cloud Base - LDAP via Knox, transport HTTP
jdbc:impala://knox-lb.example.local:8443/analytics;
  AuthMech=3;SSL=1;
  TransportMode=http;httpPath=gateway/cdp-proxy-api/impala;
  SSLTrustStore=/etc/knox/knox-truststore.jks;
  SSLTrustStorePwd=<MOT_DE_PASSE_TRUSTSTORE>

# CDP Public Cloud (Data Hub) - port 443, chemin préfixé par le nom du Data Hub
jdbc:impala://<hote-knox-datahub>:443/analytics;
  AuthMech=3;SSL=1;
  TransportMode=http;httpPath=<nom-datahub>/cdp-proxy-api/impala;
  SSLTrustStore=...;SSLTrustStorePwd=...
```

Cloudera ou Hive : choisir un seul couple

Pilote Cloudera : classe `com.cloudera.impala.jdbc.Driver` et URL `jdbc:impala://`. Pilote Hive : classe `org.apache.hive.jdbc.HiveDriver` et URL `jdbc:hive2://`. Les paramètres d'authentification, de transport et TLS ne sont pas interchangeables. Ne mélangez jamais le pilote Cloudera et une URL `jdbc:hive2://`.

5.7 Tester le JAR indépendamment du FDW, sous l'identité postgres

Ce test reproduit le mécanisme de `jdbc_fdw` (propriétés JDBC standard user et password) : il valide en même temps la compatibilité d'identité signalée au §5.8.

Java - KnoxImpalaTest.java

```
import java.sql.*;

public class KnoxImpalaTest {
    public static void main(String[] args) throws Exception {
        String url = args[0];
        String user = args[1];
        String pwd = new String(System.console().readPassword("Mot de passe LDAP : "));
        Class.forName("com.cloudera.impala.jdbc.Driver");
        try (Connection cn = DriverManager.getConnection(url, user, pwd);
            Statement st = cn.createStatement();
            ResultSet rs = st.executeQuery(
                "SELECT COUNT(*) FROM analytics.v_ventes_powerbi")) {
            while (rs.next()) System.out.println("count = " + rs.getLong(1));
        }
    }
}
```

Shell - compilation et exécution

```
JAR=/opt/cloudera/impala-jdbc/ImpalaJDBC42.jar
URL='jdbc:impala://knox-lb.example.local:8443/analytics;AuthMech=3;SSL=1;'
URL="${URL}TransportMode=http;httpPath=gateway/cdp-proxy-api/impala;"
URL="${URL}SSLTrustStore=/etc/knox/knox-truststore.jks;SSLTrustStorePwd=<MOT_DE_PASSE_TRUSTSTORE>"
javac KnoxImpalaTest.java
sudo -u postgres java -cp ".$JAR" KnoxImpalaTest "$URL" svc_powerbi_impala
```

Attendu : count = même valeur que côté Impala. Une exception « PKIX path building failed » renvoie au truststore ; un message contenant « HTTP Response code: 401/403/404 » renvoie au tableau du §3.5.

5.8 Créer le serveur JDBC**PostgreSQL SQL - URL sans UID/PWD**

```
CREATE EXTENSION jdbc_fdw;
CREATE SCHEMA IF NOT EXISTS impala_ext AUTHORIZATION fdw_owner;

CREATE SERVER impala_jdbc_knox_srv
  FOREIGN DATA WRAPPER jdbc_fdw
  OPTIONS (
    drivename 'com.cloudera.impala.jdbc.Driver',
    -- Les littéraux adjacents séparés par des sauts de ligne
    -- sont concaténés par PostgreSQL.
    url 'jdbc:impala://knox-lb.example.local:8443/analytics;'
      'AuthMech=3;SSL=1;'
      'TransportMode=http;httpPath=gateway/cdp-proxy-api/impala;'
      'SSLTrustStore=/etc/knox/knox-truststore.jks;'
      'SSLTrustStorePwd=<MOT_DE_PASSE_TRUSTSTORE>',
    jarfile '/opt/cloudera/impala-jdbc/ImpalaJDBC42.jar',
    querytimeout '300',
    maxheapsize '512',
    updatable 'false'
  );

CREATE USER MAPPING FOR pbi_reader
  SERVER impala_jdbc_knox_srv
  OPTIONS (
    username 'svc_powerbi_impala',
    password '<MOT_DE_PASSE_LDAP_IMPALA>'
  );
```

Compatibilité des propriétés d'identité

jdbc_fdw transmet le mapping comme propriétés JDBC standard user / password, tandis que le guide Cloudera illustre souvent UID / PWD dans l'URL. Le test du §5.7 valide ce comportement avec le JAR exact. Ne placez UID/PWD dans l'URL qu'en dernier recours, car l'URL du serveur est visible dans les catalogues PostgreSQL.

5.9 Créer les foreign tables manuellement**PostgreSQL SQL**

```
CREATE FOREIGN TABLE impala_ext.ventes_jdbc_knox (
  vente_id      bigint,
  client_id     bigint,
  date_vente    timestamp without time zone,
  montant       numeric(18,2),
  pays         text,
  date_partition date
)
SERVER impala_jdbc_knox_srv
OPTIONS (
  schema_name 'analytics',
  table_name 'v_ventes_powerbi',
  updatable 'false'
);
-- Exemple si la colonne distante conserve une casse particulière :
-- pays text OPTIONS (column_name 'Pays')
```

Le README est incomplet sur les options de table, mais le code de v0.5.0 expose `schema_name`, `table_name` et `column_name`. N'utilisez pas `IMPORT FOREIGN SCHEMA` pour Impala : l'amont le limite actuellement à GridDB.

5.10 Durcir jdbc_fdw et valider

`jdbc_fdw` est génériquement inscriptible et fournit `jdbc_exec`, qui peut exécuter du SQL arbitraire. Pour ce cas Power BI, conservez trois barrières : `updatable=false`, aucune colonne key, et compte Impala limité à `SELECT`.

PostgreSQL SQL - inventaire puis contrôle des droits

```
REVOKE ALL ON FOREIGN SERVER impala_jdbc_knox_srv FROM PUBLIC;
GRANT USAGE ON FOREIGN SERVER impala_jdbc_knox_srv TO pbi_reader;

-- Selon la signature installée, révoquer les fonctions jdbc_exec
-- exposées à PUBLIC après inventaire :
SELECT n.nspname, p.proname, pg_get_function_identity_arguments(p.oid)
FROM pg_proc p
JOIN pg_namespace n ON n.oid = p.pronamespace
WHERE p.proname = 'jdbc_exec';

SET ROLE pbi_reader;
SELECT COUNT(*) FROM impala_ext.ventes_jdbc_knox;
EXPLAIN (VERBOSE, COSTS, SETTINGS)
SELECT vente_id, montant
FROM impala_ext.ventes_jdbc_knox
WHERE date_partition = DATE '2026-08-31';
RESET ROLE;
```

5.11 Pushdown et limites à connaître

Fonction	État annoncé	Action
WHERE	Pushdown	Vérifier les opérateurs et types avec EXPLAIN
Projection de colonnes	Pushdown	Sélectionner uniquement les colonnes utiles
SUM, AVG, MIN, MAX, COUNT, STDDEV, VAR	Pushdown annoncé	Tester la requête distante et l'exactitude
GROUP BY	Non pris en charge par l'amont	Pré-agréger dans la vue Impala
ORDER BY et casts	Non pris en charge	Éviter de compter sur le pushdown
Transactions, RETURNING, TRUNCATE	Non pris en charge	Lecture seule
ARRAY PostgreSQL	Non pris en charge	Aplatir les types complexes
IMPORT FOREIGN SCHEMA	GridDB seulement	DDL manuel versionné

Coût JVM

Une JVM est intégrée aux processus backend PostgreSQL qui utilisent le FDW. Mesurez RSS, heap, sessions Impala et comportement après annulation. Limitez la concurrence et la mémoire avant d'ouvrir DirectQuery.

5.12 Particularités Knox côté JDBC

- **Cookies de stickiness** : si Knox répartit sur plusieurs coordinateurs, le pilote doit renvoyer le cookie `KNOX_BACKEND-IMPALA` à chaque appel Thrift (chaque `ExecuteStatement`, `GetOperationStatus` et `FetchResults` est une requête HTTP distincte). Testez explicitement avec au moins deux coordinateurs derrière Knox ; un retour d'expérience Cloudera montre qu'un pilote ODBC peut échouer (HTTP 500) sur une topologie sticky là où le pilote JDBC fonctionne. En cas de doute, demandez une stickiness garantie par le LB en amont de Knox, ou un seul backend Impala pour le PoC.
- **Une JVM par backend** : le coût JVM s'ajoute à la latence HTTP. Fixez `maxheapsize`, limitez la concurrence et mesurez le RSS avant tout DirectQuery.
- **Connexions conservées** : `jdbc_fdw` garde la connexion ouverte dans le backend PostgreSQL ; sa durée de vie doit rester sous `idle_session_timeout` Impala et sous les délais d'inactivité du LB devant Knox, sinon la première requête après une pause échoue.

6. Couche PostgreSQL commune et sécurisée

Power BI ne doit pas accéder directement au schéma `impala_ext`. Une vue reporting stabilise les noms, cache l'implémentation FDW (et le passage par Knox) et centralise les règles de filtrage.

6.1 Exposer une vue de reporting

PostgreSQL SQL

```
CREATE SCHEMA reporting AUTHORIZATION fdw_owner;

-- Choisir une seule source après le PoC : ventes_odbc_knox OU ventes_jdbc_knox.
CREATE VIEW reporting.ventes AS
SELECT
    vente_id,
    client_id,
    date_vente,
    montant,
    pays,
    date_partition
FROM impala_ext.ventes_odbc_knox;

REVOKE ALL ON SCHEMA impala_ext FROM PUBLIC;
REVOKE ALL ON ALL TABLES IN SCHEMA impala_ext FROM PUBLIC;
REVOKE ALL ON SCHEMA reporting FROM PUBLIC;

GRANT CONNECT ON DATABASE bi_gateway TO pbi_reader;
GRANT USAGE ON SCHEMA reporting TO pbi_reader;
GRANT SELECT ON reporting.ventes TO pbi_reader;
```

6.2 Protéger PostgreSQL

Configuration PostgreSQL

```
# postgresql.conf - valeurs d'exemple
ssl = on
password_encryption = 'scram-sha-256'
statement_timeout = '300s'
idle_in_transaction_session_timeout = '60s'

# pg_hba.conf - IP de la Gateway, à adapter
hostssl bi_gateway pbi_reader 10.20.30.40/32 scram-sha-256
```

Installez une chaîne de certificats reconnue par Desktop et Gateway. N'utilisez pas d'exception de validation TLS en production, ni côté Power BI, ni côté Knox. Restreignez le pare-feu à l'IP de la Gateway et aux postes d'administration autorisés.

6.3 Secrets

- Le mot de passe PostgreSQL du rôle `pbi_reader` est stocké dans la source de données Gateway, avec rotation planifiée.
- Le secret transmis à Knox est le **mot de passe LDAP** de `svc_powerbi_impala`. Il vit dans le USER MAPPING, donc dans les catalogues et sauvegardes PostgreSQL : restreindre leur lecture, chiffrer les sauvegardes, organiser la rotation, et connaître la **politique de verrouillage LDAP** avant tout test de charge.
- Rotation : changer le mot de passe dans l'annuaire, puis `ALTER USER MAPPING ... OPTIONS (SET odbc_PWD '...')` ou `(SET password '...')`, puis un `SELECT` de contrôle **avant** le prochain refresh Power BI.
- Les URL et DSN ne doivent pas contenir le mot de passe Impala si le mapping fonctionne.
- Aucun keytab ni cache Kerberos n'est nécessaire sur le serveur PostgreSQL : simplification réelle par rapport à un accès direct kerberisé.
- Le mot de passe du truststore JKS protège l'intégrité d'un magasin de CA, mais il est visible dans `pg_foreign_server` ; préférez la CA dans le cacerts du JDK (§5.3) si votre politique l'exige.
- Les jetons Knox (JWT) existent et certaines versions des pilotes Cloudera les acceptent, mais ils **expirent** : peu adaptés à un USER MAPPING statique, à n'envisager qu'avec une rotation automatisée et après vérification du

guide du pilote.

6.4 Paramètres de délai cohérents

Couche	Paramètre	Exemple	Remarque
Power BI / Gateway	Command timeout	300 s	-
PostgreSQL	statement_timeout	300 s	-
jdbc_fdw	querytimeout	300 s	-
Pilote Cloudera	Délais socket / HTTP du pilote (noms selon guide livré)	300 s ou plus	ODBC et JDBC
Knox	gateway.httpclient.socketTimeout	320 s	20 s par défaut : un FetchResults lent est coupé
Knox	gateway.httpclient.connectionTimeout	20 s	Peut rester court
Knox	gateway.httpclient.maxConnections	Au moins le nombre de backends PostgreSQL simultanés	32 par hôte:port par défaut
Load balancer devant Knox	Idle / session timeout	Supérieur à la requête HTTP la plus longue	Et stickiness si Knox est en cluster
Impala	QUERY_TIMEOUT_S, idle_session_timeout	Inférieur ou égal au SLO ; supérieur à la vie des connexions FDW	-

Les paramètres Knox sont globaux (gateway-site.xml) ou surchargés par service dans la topologie (httpClient.socketTimeout sur IMPALA). Ils sont modifiés par l'équipe plateforme, dans une fenêtre de changement, et doivent être tracés dans le dossier de livraison.

7. Connexion Power BI à PostgreSQL

Mode recommandé : Import

Import réduit les aller-retours et protège Impala et Knox contre la concurrence interactive. Utilisez un rafraîchissement incrémentiel si la table contient une colonne date fiable. DirectQuery ne doit être ouvert qu'après test de charge de bout en bout, Knox compris.

7.1 Power BI Desktop

1. Dans Power BI Desktop : Obtenir les données -> PostgreSQL database.
2. Serveur : pg-bi.example.local:5432. Base : bi_gateway.
3. Choisir Import par défaut ; choisir DirectQuery uniquement si le dossier d'architecture l'autorise.
4. S'authentifier avec le rôle PostgreSQL pbi_reader et exiger la connexion chiffrée.
5. Sélectionner uniquement reporting.ventes, pas les foreign tables brutes.
6. Dans Power Query, conserver les filtres sur dates au plus tôt et contrôler le query folding avec les outils de diagnostic.
7. Publier le modèle, puis l'associer à la source Gateway correspondante.

7.2 Gateway Power BI Service

Champ	Valeur
Type	PostgreSQL
Server	pg-bi.example.local:5432
Database	bi_gateway
Authentication	Basic / Database selon interface
Username	pbi_reader
Encryption	Activée ; certificat valide
Privacy level	Organizational, selon gouvernance

La passerelle standard doit être installée sur un serveur toujours disponible et capable de résoudre le DNS PostgreSQL. Utilisez un cluster de passerelles si votre SLO l'exige.

7.3 Import ou DirectQuery

Sujet	Import	DirectQuery
Latence visuelle	Faible après chargement	Dépend de PG, du FDW, de Knox et d'Impala
Charge Impala et Knox	Pendant les rafraîchissements	À chaque interaction
Fraîcheur	Selon planification	Proche de la source
Tolérance aux pannes Impala / Knox	Rapports restent consultables	Visuels en erreur
Choix	Par défaut	Seulement après SLO et charge validés

8. Plan de tests et critères d'acceptation

8.1 Exactitude fonctionnelle

Test	Impala	PostgreSQL	Power BI	Acceptation
Nombre de lignes	COUNT(*)	COUNT(*) vue reporting	Mesure	Identique à l'instant T
Clé métier	COUNT DISTINCT	COUNT DISTINCT	Mesure	Identique
Montant	SUM DECIMAL	SUM numeric	Mesure fixe	Écart 0 selon règle
NULL	Par colonne	Par colonne	Profil	Identique
Dates	MIN/MAX	MIN/MAX	Filtre calendrier	Aucun décalage de jour
Texte	Accents/casse	Accents/casse	Visuel	UTF-8 intact
Sécurité	Compte SELECT	SET ROLE	Compte Gateway	Aucune table brute visible
Identité via Knox	Delegated User	Mapping pbi_reader	-	svc_powerbi_impala dans profil et audit Knox

8.2 Performance

Définissez les chiffres avant le test. Exemple de critères à remplacer par vos SLO :

Indicateur	Cible exemple	Mesure
Rapport Import - rafraîchissement	< 30 min	Power BI + profil Impala
DirectQuery simple	P95 < 5 s	Performance Analyzer
DirectQuery complexe	P95 < 15 s	Performance Analyzer
Concurrence	20 utilisateurs	Test simultané réaliste
Requête longue via Knox	Pas de coupure vers 20 s	Requête > 60 s avant tout ajustement Knox
Connexions Knox actives	Sous maxConnections	Journaux et métriques Knox
RSS backend JDBC	Budget défini	ps / cgroups / supervision
Sessions Impala	Sous quota	Admission control
Annulation	< 10 s	Annuler un visuel et vérifier Impala

8.3 Résilience

- Couper temporairement la route vers Knox dans un environnement de test et observer le timeout complet.
- Redémarrer Knox ; confirmer la reprise automatique des foreign tables (nouvelle connexion).
- Arrêter un coordinateur derrière Knox ; nouvelles sessions OK, sessions en cours conformes à noFallback.
- Annuler une requête longue depuis PostgreSQL et Power BI ; vérifier qu'elle disparaît d'Impala.
- Changer le mot de passe LDAP selon la procédure de rotation et confirmer la reprise sans secret résiduel ni verrouillage.
- Redémarrer PostgreSQL ; valider le chargement de l'extension, de libjvm et des pilotes.
- Pour Import, confirmer que le dernier jeu importé reste visible pendant une panne Impala ou Knox.

8.4 Tests spécifiques Knox

Test	Procédure	Acceptation
Requête longue	Requête Impala > 60 s via la foreign table, avant tout ajustement Knox	Résultat complet ; pas de coupure vers 20 s
Gros fetch	SELECT de plusieurs millions de lignes sans filtre	Débit acceptable ; comparer au chemin direct si disponible
Concurrence	20 sessions PostgreSQL simultanées (pgbench ou script)	Aucune erreur de connexion Knox ; sessions Impala sous quota
Stickiness	Au moins deux coordinateurs derrière Knox, 20 requêtes multi-fetch	Aucune erreur de session ou de handle invalide
Verrouillage LDAP	Mauvais mot de passe volontaire dans un mapping de test	Compte de production intact ; seuil de verrouillage connu
Audit	Requête traçable (/* test-knox-42 */)	Visible dans gateway-audit.log (utilisateur, chemin, 200) et dans le profil Impala (Delegated User)

8.5 Comparaison A/B

PostgreSQL SQL - compléter avec profils Impala et journaux Knox

```
-- Exécuter avec les mêmes filtres et sous le même rôle.
EXPLAIN (ANALYZE, VERBOSE, BUFFERS, TIMING)
SELECT date_partition, SUM(montant)
  FROM impala_ext.ventes_odbc_knox
 WHERE date_partition BETWEEN DATE '2026-08-01' AND DATE '2026-08-31'
 GROUP BY date_partition;

EXPLAIN (ANALYZE, VERBOSE, BUFFERS, TIMING)
SELECT date_partition, SUM(montant)
  FROM impala_ext.ventes_jdbc_knox
 WHERE date_partition BETWEEN DATE '2026-08-01' AND DATE '2026-08-31'
 GROUP BY date_partition;
```

9. Exploitation et diagnostic

9.1 Supervision minimale

Couche	Mesures
Power BI	Durée de refresh, échecs Gateway, P95 visuels, requêtes
PostgreSQL	pg_stat_activity, timeouts, erreurs FDW, CPU/RSS, connexions
JDBC	RSS backend, heap, erreurs JNI/JVM, libjvm, sessions
ODBC	Erreurs unixODBC/pilote, connexions, résolution DSN
Knox	gateway-audit.log (codes 401/403/404/5xx), gateway.log, connexions httpclient, délais, certificats
Impala	Admission control, mémoire, scan bytes, profils, sessions, annulations
Réseau/TLS	Latence, pertes, expirations de certificats (Knox et PostgreSQL), DNS

9.2 Symptômes fréquents

Symptôme	Cause probable	Diagnostic
isql ne se connecte pas	DSN, pilote, réseau, TLS, LDAP Knox	Tester comme postgres ; journaux pilote ; audit Knox
CREATE EXTENSION échoue ODBC	Module absent ou dépendance	pg_config, ldd, répertoire extension
libjvm.so not found	Chargeur dynamique	ldd jdbc_fdw.so ; systemd/ldconfig
ClassNotFoundException	Mauvais JAR/classe ou dépendances	Manifeste, classe, JAR autonome
Connexion JDBC renvoie null	URL non reconnue par le pilote	Vérifier jdbc:impala et version exacte
Erreur pilote « HTTP Response code: 401 »	Mot de passe LDAP, compte verrouillé, mauvais annuaire	curl -u (§3.5), gateway-audit.log, état du compte
« 403 »	ACL topologie / politique Ranger Knox, ou Impala refuse l'impersonation	gateway.log, politiques Ranger Knox, authorized_proxy_user_config
« 404 »	HttpPath faux (chemin gateway, topologie, /impala)	Page d'accueil Knox ou fichier de topologie
« 502 » / « 503 »	Knox ne joint pas impalad:28000 (HS2 HTTP désactivé, TLS Knox -> Impala, url obsolète)	curl depuis l'hôte Knox vers un coordinateur ; gateway.log
Coupure vers 20 s, connection reset, « 504 »	gateway.httpclient.socketTimeout par défaut	Test requête longue (§8.4) ; augmenter côté Knox
Session ou query handle invalide, résultats tronqués	Round robin Knox sans stickiness, ou pilote qui ignore le cookie	HaProvider de la topologie ; tester avec un seul backend
PKIX path building failed (JDBC) / erreur de certificat (ODBC)	CA Knox absente du truststore ou du PEM ; SAN différent	openssl s_client (§3.5) ; keytool -list
isql OK mais foreign table en échec	Mapping (odbc_UID/odbc_PWD, username/password) ou rôle	\deu+ ; SET ROLE pbi_reader
Compte LDAP verrouillé	Mot de passe faux dans un USER MAPPING + retries Power BI	Corriger le mapping avant de déverrouiller
Requête OK mais Ranger Impala refuse	Utilisateur effectif = identité Knox et non svc_powerbi_impala	Profil Impala (Connected / Delegated User) ; confiance Impala <-> Knox
Invalid option schema_name	Version différente du code prévu	SELECT extversion + SHA du binaire
Table introuvable	Casse, base, schema_name/table_name	DESCRIBE Impala ; column_name
Décimales différentes	Mapping ou cast	Vue DECIMAL(p,s), numeric(p,s), cas limites
DirectQuery lent	Pushdown perdu, transport HTTP + Knox, RowsFetchedPerBlock, trop de visuels	EXPLAIN, profils Impala, Analyzer, A/B
Trop de sessions	Concurrence Gateway/backends ; maxConnections Knox	pg_stat_activity, sessions Impala, quotas, journaux Knox

9.3 Requêtes de diagnostic PostgreSQL

PostgreSQL SQL

```
SELECT extname, extversion FROM pg_extension
WHERE extname IN ('odbc_fdw', 'jdbc_fdw');

SELECT srvname, fdwname, srvoptions
FROM pg_foreign_server s
JOIN pg_foreign_data_wrapper f ON f.oid = s.srvfdw;  -- url/dsn, aucun secret inutile

SELECT um.umuser::regrole, s.srvname, um.umoptions
FROM pg_user_mapping um
JOIN pg_foreign_server s ON s.oid = um.umserver;  -- réservé aux administrateurs

SELECT pid, username, application_name, state,
       wait_event_type, wait_event, query_start, left(query, 120)
FROM pg_stat_activity
WHERE datname = 'bi_gateway'
ORDER BY query_start;
```

10. Retour arrière et recommandation finale

10.1 Basculer de JDBC vers ODBC, ou inversement

La vue reporting.ventes sert d'interface stable. Une bascule contrôlée peut être effectuée en remplaçant sa source dans une transaction, après test d'exactitude et drain des requêtes. Le même mécanisme permet de revenir à un accès direct si Knox devait être retiré du chemin.

PostgreSQL SQL

```
BEGIN;
CREATE OR REPLACE VIEW reporting.ventes AS
SELECT vente_id, client_id, date_vente, montant, pays, date_partition
FROM impala_ext.ventes_jdbc_knox; -- ou ventes_odbc_knox
COMMIT;
-- Valider ensuite les mesures de référence et un refresh Power BI.
```

10.2 Retirer une méthode

Ne supprimez rien tant que la vue reporting, Power BI et les tableaux de bord ne sont pas validés sur l'autre chemin. Exportez d'abord les DDL et gardez les paquets, pilotes, CA et hashes nécessaires à une restauration.

psql / SQL - commandes destructives volontairement commentées

```
-- Inventaire avant suppression
\det+ impala_ext.*
\des+
\deu+

-- Après validation et fenêtre de changement seulement :
-- DROP FOREIGN TABLE impala_ext.ventes_jdbc_knox;
-- DROP SERVER impala_jdbc_knox_srv CASCADE;
-- DROP EXTENSION jdbc_fdw;
```

10.3 Recommandation

Contexte	Recommandation
PoC rapide avec couche PostgreSQL obligatoire	ODBC FDW 0.6.1 via Knox, vues Impala dédiées, Power BI Import
JDBC imposé par standard interne	jdbc_fdw v0.5.0 sur PG17 via Knox, JDK/JAR figés, PoC et charge
Knox imposé comme point d'entrée	Chemin standard de ce guide ; aligner délais, connexions et stickiness Knox avant tout DirectQuery
DirectQuery à forte concurrence	Évaluer connecteur Impala direct ou couche locale matérialisée
Production critique / faible tolérance aux pannes	ETL/ELT vers tables PostgreSQL locales avec SLA
Aucune valeur ajoutée de PostgreSQL	Connecteur Power BI Impala natif, si compatible avec votre mode d'accès

Verdict

Le montage est réalisable. Pour réduire le risque : PostgreSQL 17, foreign tables en lecture seule, vues Impala aplaties, vue PostgreSQL reporting, TLS de bout en bout (Power BI, PostgreSQL, Knox), délais et connexions Knox alignés, Power BI Import, et validation A/B. Le statut communautaire des FDW et la dépendance à Knox doivent être acceptés explicitement par l'exploitation et la sécurité.

11. Références et checklist de mise en service

11.1 Références primaires

Réf.	Document	Lien
R1	Apache Impala - Configuring JDBC and ports	https://impala.apache.org/docs/build/html/topics/impala_jdbc.html
R2	Cloudera - JDBC Connector for Impala 2.6.39	https://www.cloudera.com/downloads/connectors/impala/jdbc/2-6-39.html
R3	Cloudera - ODBC Connector for Impala 2.9.0	https://www.cloudera.com/downloads/connectors/impala/odbc/2-9-0.html
R4	odbc_fdw fork archivé	https://github.com/devrimgunduz/odbc_fdw
R5	odbc_fdw 0.6.1 - correctifs de sécurité	https://github.com/devrimgunduz/odbc_fdw/releases/tag/0.6.1
R6	pgspider jdbc_fdw - README	https://github.com/pgspider/jdbc_fdw/blob/main/README.md
R7	pgspider jdbc_fdw v0.5.0	https://github.com/pgspider/jdbc_fdw/releases/tag/v0.5.0
R8	jdbc_fdw - options réelles dans le code	https://github.com/pgspider/jdbc_fdw/blob/main/option.c
R9	Microsoft - Connecteur PostgreSQL Power Query	https://learn.microsoft.com/en-us/power-query/connectors/postgresql
R10	Microsoft - DirectQuery dans Power BI	https://learn.microsoft.com/en-us/power-bi/connect-data/desktop-direct-query-about
R11	Microsoft - Sources de données Gateway	https://learn.microsoft.com/en-us/power-bi/connect-data/service-gateway-datasources
R12	Microsoft - Connecteur Impala Power Query	https://learn.microsoft.com/en-us/power-query/connectors/impala-database
R13	PostgreSQL - Foreign data	https://www.postgresql.org/docs/current/ddl-foreign-data.html
K1	Cloudera - Configuring JDBC for Impala (HTTP, port 28000, jdbc:impala)	https://docs.cloudera.com/cdp-private-cloud-base/7.3.1/impala-configure/topics/impala-jdbc.html
K2	Apache Knox - User's Guide (gateway.httpclient.*, topologies, HaProvider)	https://knox.apache.org/books/knox-2-1-0/user-guide.html
K3	Apache Knox - Load-balancing and sticky session support	https://cwiki.apache.org/confluence/display/KNOX/Knox+load-balancing+and+sticky+session+support+for+backend+services
K4	Cloudera - Configure Apache Knox load balancing	https://docs-archive.cloudera.com/runtime/7.2.9/knox-authentication/topics/security-knox-configure-ha.html
K5	KNOX-3004 - URL JDBC Impala sur la page d'accueil Knox	https://issues.apache.org/jira/browse/KNOX-3004
K6	Guides Cloudera des connecteurs ODBC et JDBC (clés TransportMode, HttpPath, TrustedCerts, SSLTrustStore)	Guide PDF livré avec chaque ZIP (R2, R3)

11.2 Checklist go/no-go

- [] Vue Impala dédiée, types complexes aplatis, droits SELECT seulement pour svc_powerbi_impala.
- [] HttpPath, port et topologie Knox confirmés par l'équipe plateforme ou copiés depuis la page d'accueil Knox.
- [] HS2 HTTP (28000) actif sur tous les coordinateurs référencés dans la topologie ; confiance Impala <-> Knox en place.
- [] PostgreSQL 17, extension et pilotes épinglés avec hashes et paquets internes ; version et paramètres Knox tracés.
- [] Chaîne CA Knox installée : PEM lisible par postgres (ODBC) et truststore JKS (JDBC) ; aucun mode trust-all.
- [] openssl s_client et curl -u validés ; entrée correspondante vue dans gateway-audit.log.
- [] isql (ODBC) ou KnoxImpalaTest (JDBC) réussi sous l'utilisateur système postgres.
- [] USER MAPPING pour pbi_reader testé par SET ROLE ; aucun secret dans l'URL ou le DSN si évitable.
- [] Profil Impala : Delegated User = svc_powerbi_impala ; politiques Ranger Knox et Impala en place.
- [] reporting.* est la seule surface exposée à Power BI.

- [] Exactitude COUNT/SUM/DECIMAL/DATE/NULL/UTF-8 validée.
- [] EXPLAIN VERBOSE et profil Impala archivés pour les requêtes de référence.
- [] gateway.httpClient.socketTimeout et maxConnections alignés ; requête longue et gros fetch testés.
- [] Stickiness validée avec au moins deux coordinateurs, ou topologie mono-backend assumée.
- [] P95, concurrence, mémoire, sessions et annulation conformes aux SLO.
- [] Politique de verrouillage LDAP connue ; rotation du mot de passe testée sans verrouillage.
- [] Gateway, refresh, supervision et reprise testés ; Knox en cluster ou point unique de défaillance accepté.
- [] Retour arrière testé ; DDL, guides, CA et binaires archivés.
- [] Risque de maintenance communautaire et dépendance à Knox acceptés par les responsables.

Fin du document